

Otimizacao Automatica de um Sistema Fuzzy por Computacao Evolutiva

Trabalho de Pesquisa e Desenvolvimento - Parte 2 (IA Evolutiva e Computacao Bioinspirada)

Disciplina: Inteligencia Artificial e Computacional (0700M8) - CESUPA, 2026/01 **Abordagem:** otimizacao de hiperparametros fuzzy (integra a Parte 1) com **AG** e **PSO** **Turma:** _(preencher)_ · **Integrantes:** _(preencher)_ **Repositorio:** _(link GitHub)_

Resumo

Formulamos a **sintonia das funcoes de pertinencia** do sistema fuzzy de manutencao preditiva (Parte 1) como um **problema de otimizacao** e o resolvemos com **Algoritmo Genetico (AG)** e **Otimizacao por Enxame de Particulas (PSO)**, comparando contra dois baselines: o fuzzy **manual** (especialista) e a **busca aleatoria** com o mesmo orcamento de avaliacoess. Em 5 execucoes independentes por metodo, o AG eleva o F1 da classe falha de **0,346 (manual)** para **0,576** (media; melhor 0,595), com aumento expressivo de recall (0,265 -> 0,488). O PSO atinge 0,544 e a busca aleatoria 0,477, evidenciando que o ganho vem da **busca dirigida**, e nao apenas do numero de avaliacoess.

1. Problema e objetivo

O sistema fuzzy da Parte 1, sintonizado manualmente, e interpretavel mas detecta poucas falhas (recall 0,27). Em vez de ajustar os parametros "no olho", buscamos os melhores parametros de forma **automatica**, transformando o ajuste num problema de otimizacao em espaco contínuo de 31 dimensoes. A metaheurística e tratada como o algoritmo principal exigido na Parte 2; o sistema fuzzy fornece a **funcao de aptidao**.

2. Formulacao da otimizacao

Elemento	Definicao
Variaveis de decisao	31 breakpoints ajustaveis das MFs (entradas + saida)
Representacao	vetor real; bounds = universo de cada variavel
Espaco de busca	hipercubo limitado pelos universos de discurso
Funcao objetivo	F1 da classe falha no conjunto de TREINO (maximizar)
Restricoes	ordenacao dos breakpoints ($a \leq b \leq c \leq d$), tratada por reparo (sort)
Baselines	fuzzy manual (especialista) e busca aleatoria

Os ombros das MFs presos ao limite do universo permanecem fixos, reduzindo a dimensionalidade. O limiar que converte o risco contínuo em decisao binaria e escolhido em cada avaliacao maximizando o F1 de treino; a avaliacao final usa o **teste** com o limiar fixado no treino (evitando vazamento).

3. Algoritmos

3.1 Algoritmo Genetico (real-coded)

Selecao por **torneio**, crossover **BLX-alpha**, mutacao **gaussiana** por gene e **elitismo**. A populacao inicial inclui a sintonia manual + perturbacoes + individuos aleatorios (inicializacao informada). Com elitismo, o resultado nunca piora em relacao ao baseline. Configuracao: populacao 40, 50 geracoes (2040 avaliacoess).

3.2 PSO (global-best)

Atualizacao classica de Kennedy & Eberhart com inercia $w=0,72$, coeficientes $c1=c2=1,49$, clamp de velocidade e reflexao nos limites. Configuracao: enxame 30, 50 iteracoes (1530 avaliacoess). Mesma funcao objetivo e mesma codificacao do AG, garantindo comparacao justa.

3.3 Busca aleatoria

Amostra genomas uniformemente no espaco de busca com o mesmo orcamento do AG (2040 avaliacoess). Mostra quanto do ganho vem da busca dirigida.

4. Metodologia experimental

Por serem estocásticos, todos os métodos foram executados com **5 sementes independentes** (1 a 5). Registramos qualidade (F1 melhor/pior/media/desvio), **recall**, **curvas de convergência**, **eficiência por orçamento** de avaliações e **custo computacional** (tempo, número de avaliações). O dataset é dividido uma única vez (split estratificado 70/30, semente 42) para que todos os métodos vejam os mesmos conjuntos.


5. Resultados

5.1 Qualidade da solução (5 sementes)

Metodo	F1 melhor	F1 pior	F1 media	desvio	Recall (media)	Avaliacoess	Tempo
Manual (baseline)	0,346	0,346	0,346	0,000	0,265	1	-
Busca aleatoria	0,509	0,439	0,477	0,024	0,416	2040	~18 s
PSO	0,578	0,503	0,544	0,025	0,475	1530	~13 s
Algoritmo Genetico	0,595	0,559	0,576	0,014	0,488	2040	~32 s


O AG é o melhor e o mais **estável** (menor desvio). A ordem **AG > PSO > aleatoria > manual** é consistente em todas as sementes.

5.2 Convergência e eficiência por orçamento




A esquerda mostra a convergência por geração/iteração (média +/- desvio); ambos convergem, com o AG terminando ligeiramente acima. A direita compara o melhor F1 por **número de avaliações**: o PSO é mais eficiente nas primeiras avaliações, o AG o ultrapassa adiante, e a **busca aleatória estagna** em ~0,48 - o ganho do AG/PSO não é fruto do orçamento, e sim da busca dirigida.


5.3 Antes x Depois (otimização automática dos parâmetros fuzzy)



A otimizacao reduz drasticamente os falsos negativos (falhas nao detectadas). O deslocamento das MFs e interpretavel: o termo "Novo" do desgaste foi **estreitado**, ou seja, o otimizador aprendeu que mesmo desgaste leve ja carrega risco.



5.4 Estabilidade



6. Analise critica

mais rapido por avaliacao no inicio, o AG explora mais e termina melhor e mais estavel. **Causa provavel:** o elitismo + crossover BLX do AG preservam e recombina boas regioes; o PSO global-best converge cedo para o gbest.

na semente 1), esperada ao ajustar MFs e limiar ao treino, mas **sem overfitting severo**.

valor esta na **transparencia**. A funcao objetivo e mono-objetivo (so F1); pesos de regra nao foram otimizados.

segundos, gracias ao motor fuzzy vetorizado (~8 ms por avaliacao sobre 7000 amostras).

- **Semelhancas/diferencas:** AG e PSO chegam a desempenho proximo; o PSO converge

- **Generalizacao:** ha uma folga treino->teste (ex.: AG 0,595 treino -> 0,581 teste)
- **Limitacoes:** o fuzzy nao compete com classificadores dedicados em F1 absoluto; o
- **Custo computacional:** todas as execucoes terminam em segundos a dezenas de

7. Conclusao e trabalhos futuros

A computacao evolutiva otimizou automaticamente o sistema fuzzy, elevando o F1 de ~0,35 para ~0,58 e quase dobrando o recall, **preservando a interpretabilidade**. Trabalhos futuros: otimizar tambem **pesos de regra**, usar **fitness multiobjetivo** (F1 x interpretabilidade) e **validacao cruzada**, alem de testar Evolucao Diferencial.

8. Declaracao de uso de IA

Ver docs/declaracao_ia.md.

Referencias

Kennedy & Eberhart (1995); Holland (1975); Matzka (2020). Demais em README.md.